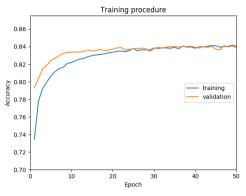
學號:b04901060 系級:電機三 姓名:黃文璁

1. (1%) 請說明你實作的 RNN model,其模型架構、訓練過程和準確率為何? (Collaborators: 無) 答:

Layer (type)	Output Shape	Param #
======================================	(None, 40, 512)	1181184
gru_8 (GRU)	(None, 512)	1574400
dense_10 (Dense)	(None, 512)	262656
dense_11 (Dense)	(None, 512)	262656
dense_12 (Dense)	(None, 1)	513
Total params: 3,281,409 Trainable params: 3,281,409 Non-trainable params: 0		



首先大致對文字資料進行下列預處理:

- 1. 只保留 ".?!" 三種標點符號和英文、數字。
- 2. 處理疊字問題。由於文字來源是 Twitter 故有許多疊字出現。
- 3. 處理基本的 stemming 和詞頻低於一定值的詞。

預處理後利用 gensim 的 word2vec 進行 word embedding,維度為256。

RNN 架構為: 兩層 GRU: units=512, dropout=0.5, recurrent_dropout=0.5

兩層 Dense: units=512, activation='selu'

訓練時的 optimizer 為 Adam, loss 使用 binary_crossentropy。

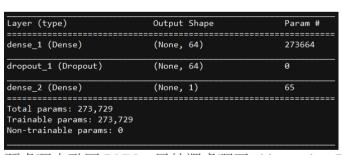
由上圖, training 和 validation accuracy 大概都在 25 個 epoch 時收斂到約 0.835。

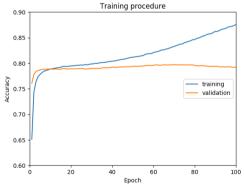
Kaggle 上的準確率為: Public: 0.83533 Private: ???????

此外還實作了8個模型的 ensemble,其他模型和上述的模型參數有些不同。

Kaggle 上的準確率為: Public: 0.83955 Private: ???????

2. (1%) 請說明你實作的 BOW model,其模型架構、訓練過程和準確率為何? (Collaborators: 無) 答:





預處理大致同 RNN,另外還處理了 skipwords,BOW 的維度約為 4000。

BOW 架構為: Dense: units=64, activation='relu'

Dropout: rate=0.2

訓練時的 optimizer 為 Adam,loss 使用 binary_crossentropy。

由上圖, validation accuracy 大概在 5 個 epoch 時收斂到約 0.79。

另外可以觀察到 RNN 相比, BOW 有更明顯的 overfit 情況。

Kaggle 上的準確率為: Public: ??????? Private: ???????

3. (1%) 請比較 bag of word 與 RNN 兩種不同 model 對於"today is a good day, but it is hot"與 "today is hot, but it is a good day"這兩句的情緒分數,並討論造成差異的原因。 (Collaborators: 無) 答:

就我們看來,第一個句子稍偏負面,而第二個句子則較明確為正面。

PredictionLabel使用 RNN 來預測兩句話,得到的結果為:第一句: 0.1657590第二句: 0.9928741使用 BOW 來預測兩句話,得到的結果為:第一句: 0.6806861第二句: 0.6806861

可以觀察到 RNN 對這兩句話的情緒都較為肯定(預測結果很接近0或1)

而 BOW 則顯然無法分辨這兩句話的情緒差異,這是由於兩個句子中的詞頻率相同。對 RNN 來說,會考慮到前後關係,故應能根據 'but' 的語氣轉折預測出正確的結果。而 BOW 則無法判斷前後文,故語氣有轉折的句子就有可能判斷錯誤。

- 4. (1%) 請比較"有無"包含標點符號兩種不同 tokenize 的方式,並討論兩者對準確率的影響。 (Collaborators: 無) 答:
- 5. (1%) 請描述在你的 semi-supervised 方法是如何標記 label,並比較有無 semi-surpervised training 對準確率的影響。

(Collaborators: 無) 答: